Traitement des données PMSI avec R

 $Guillaume\ Pressiat\ ||\ SIMAP\ /\ DOMU\ /\ Assistance\ Publique\ -\ H\^opitaux\ de\ Paris\\2017-02-11$

Contents

| 1 | Introduction | 5 |
|---|---|----------------------------------|
| 2 | Contexte et motivations 2.1 Avantages de R | 7 7 8 8 |
| 3 | Les archives PMSI3.1 Arborescence des archives | 9 9 11 11 |
| 4 | Import des données 4.1 MCO 4.2 HAD 4.3 SSR 4.4 PSY 4.5 RSF 4.6 Dictionnaire de variables | 15 17 19 19 19 20 |
| 5 | Requêtes sur des pathologies / actes 5.1 Transposition des codes diagnostics | 21 21 21 22 |
| 6 | Étude des files actives6.1 Import des données Anohosp6.2 File active d'une pathologie6.3 File active d'une chirurgie | 23 23 23 23 |
| 7 | Fichier TRA 7.1 Ajout du TRA en MCO 7.2 Ajout du TRA en HAD 7.3 Ajout du TRA en SSR 7.4 Ajout du TRA en PSY | 25 25 25 26 26 |
| 8 | Statistiques du PMSI | 27 |
| 9 | Help | 29 |

4 CONTENTS

Introduction

Ce livret numérique présente des exemples de traitements de données PMSI avec R. L'objectif est de concentrer ici :

- $\bullet\,$ une documentation permettant de débuter avec l'import de données via le package pmeasyr
- $\bullet\,$ des exemples d'analyses PMSI :
 - requêtes sur les diagnostics et les actes
 - statistiques élementaires sur des variables du PMSI
 - analyse des files actives pour une pathologie
 - analyse du case-mix et de la dms par ghm

Contexte et motivations

Les données du Programme de Médicalisation des Systèmes d'Informations (PMSI) sont souvent traitées via des logiciels spécifiques au PMSI (ou des outils statistiques / bases de données du marché) ne permettant pas de réaliser des traitements statistiques et des infographies satisfaisantes. Les départements d'information médicale sont donc souvent amenés à retraiter ces données avec R.

L'évolution récente de R intègre la manipulation de bases de données de taille importante. Le package *pmeasyr* s'inscrit dans cette veine et permet de réaliser de façon autonome l'ensemble des traitements (de l'import des données à leur analyse) avec R.

2.1 Avantages de R

2.1.1 Un flux de travail unique

En travaillant uniquement avec R, on peut mettre en place un flux de travail épuré : un seul projet, un seul programme, un seul logiciel. La traçabilité, la reproductibilité et la mise à jour des opérations sont ainsi facilitées.

Le travail avec de multiples logiciels oblige à l'export / import de fichiers entre les différents logiciels, et chaque modification du début du flux de travail génère des fichiers exportés v1, v2, ...

Avec un flux complet dans R, toute nouvelle modification est intégrée au processus de travail global. La localisation de toutes les étapes d'une analyse en un seul point évite les erreurs et la confusion lorsque l'on reprend l'analyse ultérieurement.

2.1.2 R et le PMSI

L'utilisation de R confère aux données du PMSI la liberté proposée par le logiciel :

- les requêtes sur les diagnostics et les actes peuvent s'écrire de multiples façons et c'est l'utilisateur qui crée ses propres programmes
- les données sont dans R : prêtes pour des modèles linéaires, logistiques, des classifications...
- la confrontation des données in* (reflet du codage des établissements) aux données out* (reflet de la valorisation accordée à l'établissement) est facilitée par l'import du fichier tra, cela peut permettre aux équipes DIM d'améliorer leur recueil
- le reporting de l'activité en excel, pdf, word, html, ou en créant des applications (shiny)
- l'utilisation des graphiques pour représenter des volumes d'activités et des cartographies interactives pour visualiser la localisation d'activités, de patientèles, et les flux de patients

• le partage de projets RStudio, qui facilite et encourage les travaux en équipe.

NB: Données In / Out : données en entrée / sortie des logiciels de l'ATIH

2.1.3 Des outils performants

L'engouement autour de R est lié au développement de packages intuitifs et performants : readr, dplyr, tidyr, magrittr, pour n'en citer que quelques-uns. pmeasyr s'appuie sur ces packages pour proposer des imports de données rapides sur des fichiers de taille importante (l'entité juridique de l'AP-HP est prise en charge sans problème avec un ordinateur récent).

Dans le cas de *pmeasyr*, l'import de 100 000 rsa (partie fixe, parsing des passages unités médicales, des diagnostics associés et des actes) nécessite en moyenne 5 secondes avec un processeur i7 – 16Go de ram.

En dernier ressort, R travaillant en mémoire vive, les exécutions de requêtes sont très rapides.

2.2 Contenu du package

Le package contient des fonctions pour la gestion des archives PMSI en entrée / sortie des logiciels de l'ATIH : dézippage, suppression des archives, et des fonctions pour l'import des fichiers des champs PMSI MCO, SSR, HAD, PSY et RSF.

Il est utilisé depuis un an à l'AP-HP pour des analyses d'activité et la description des prises en charge.

2.3 Installation du package

Depuis github avec devtools

devtools::install github('IM-APHP/pmeasyr')

Cette commande lance l'installation du package et de ses dépendances.

Les archives PMSI

Cette partie aborde le point de départ des études PMSI : les archives PMSI. Ces archives sont les fichiers en entrées / sorties des logiciels de l'ATIH.

Les manuels techniques de ces logiciels, relatifs aux champs MCO, SSR, HAD, PSY et RSF, respectivement Genrsa, Genrha, Paprica, Pivoine et Preface sont disponibules dans l'espace de telechargement sur le site de l'ATIH.

3.1 Arborescence des archives

Le package *pmeasyr* prend en charge les données des quatre champs PMSI MCO, SSR, HAD, PSY ainsi que les RSF.

Placer les archives dans un répertoire, par exemple ici dans ~/Documents/data/mco:

Vous noterez que pour chaque champ PMSI il est conseillé d'utiliser un répertoire indépendant, ceci est nécessaire dans la mesure où le nom des archives PMSI ne contient pas l'information champ MCO, RSF, etc., il faut organiser l'archivage champ par champ, dans des répertoires différents.

```
# Créer l'arborescence à partir de R
champs = c('mco', 'ssr', 'had', 'psy', 'rsf')
emplacement <- "~/Documents/data"
sapply(champs, function(x){dir.create(file.path(emplacement, x))})</pre>
```

3.2 Informations sur les archives

La fonction astat permet d'éditer des statistiques sommaires sur les fichiers contenus dans une archive.

```
Nom Fonction

astat ~ *.zip - Liste et volume des fichiers d'une archive PMSI
```

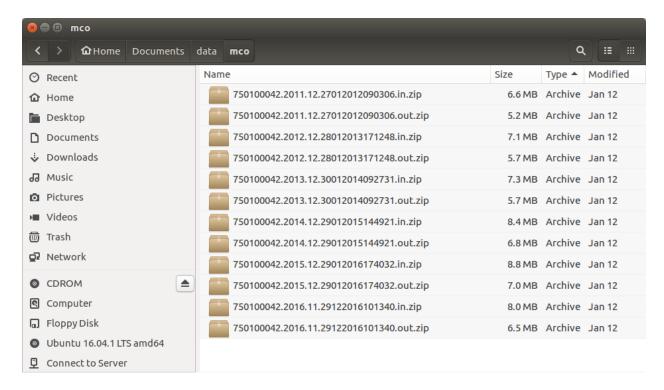


Figure 3.1: Archives MCO

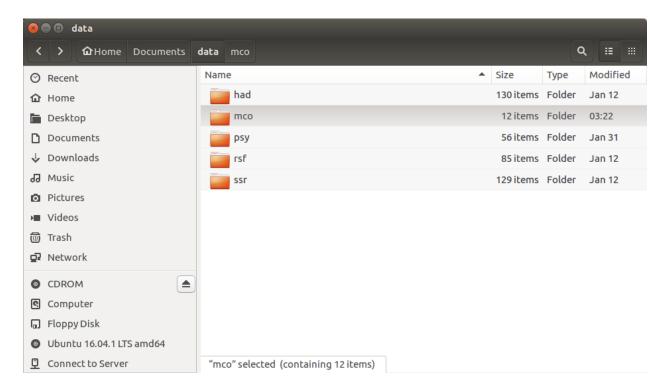


Figure 3.2: Un répertoire par champ PMSI

3.4. SUPPRESSION 11

3.3 Dézippage

Cette partie du package facilite la manipulation des archives PMSI, fichiers de type:

- finess.annee.mois.date_et_heure_de_creation.in.zip
- finess.annee.mois.date_et_heure_de_creation.out.zip

Les fonctions permettent de dézipper les fichiers depuis R en ligne de commande, sans intervention manuelle de l'utilisateur. L'avantage est d'obtenir un processus ne relevant pas d'interventions externes au logiciel R (pour pouvoir garder trace des etapes, et faciliter la reproduction, tout est inscrit dans un programme, dans un flux de processus). Une fois que les traitements et analyses sur les fichiers sont faits, il est possible d'effacer les archives également en ligne de commande.

Le nom des fonctions dont l'objectif est de manipuler les archives commence par a.

| Nom | Fonction |
|---------|---|
| adezip | ~ *.zip - Dezippe des fichiers de larchive PMSI |
| adezip2 | ~ *.zip - Dezippe des fichiers de l'archive PMSI, avec en parametre le nom de l'archive |

```
# Dezippage uniquement des fichiers rsa, ano et tra du out 2015
# Ex: 750100042.2015.12.20160130.153012.out.zip
pmeasyr::adezip(finess = 750100042,
                annee = 2015,
                mois = 12
                path = '~/Documents/data/mco',
                liste = c("rsa", "ano", "tra"),
                type = "out")
# Dezippage uniquement des fichiers rss, dmi et med du in 2015
# Ex: 750100042.2015.12.20160130.153012.out.zip
pmeasyr::adezip(finess = 750100042,
                annee = 2015,
                mois = 12,
                path = '~/Documents/data/mco',
                liste = c("rss", "dmi", "med"),
                type = "in")
```

3.4 Suppression

À la fin d'une étude, il est inutile de garder les fichiers dézippés hors de l'archive, on peut les effacer : c'est ce que permet la fonction adelete().

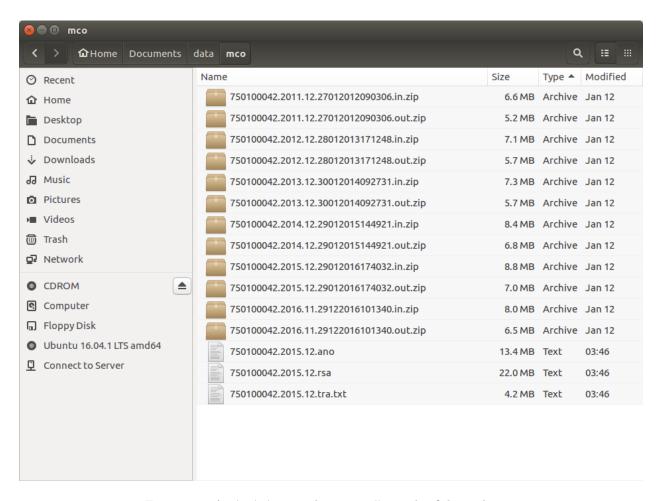


Figure 3.3: Après éxécution de adezip() sur des fichiers du out

3.4. SUPPRESSION 13

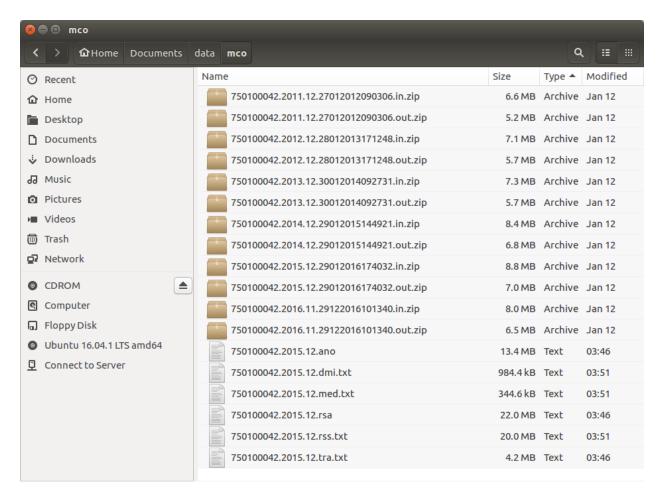


Figure 3.4: Après éxécution de adezip() sur des fichiers du in

```
path = '~/Documents/data/mco',
liste = c("rss", "med", "dmi"),
type = "in")
```

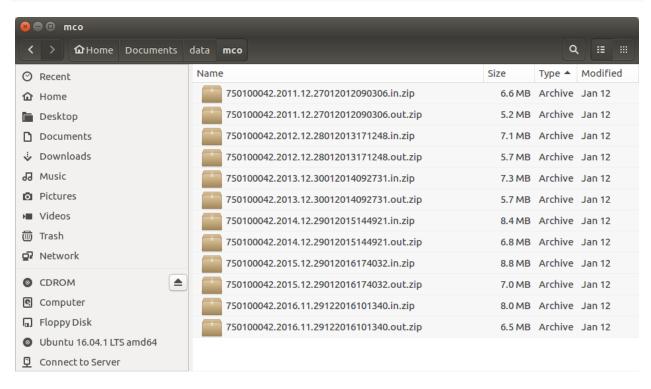


Figure 3.5: Après éxécution de adelete()

Import des données

4.1 MCO

| Nom | Fonction |
|-------------|--------------------------------------|
| irsa | ~ MCO - Import des RSA |
| irum | $\sim \mathrm{MCO}$ - Import des RUM |
| idiap | \sim MCO - Import des DIAP |
| $idmi_mco$ | $\sim \mathrm{MCO}$ - Import des DMI |
| iium | \sim MCO - Import des donnees UM |
| $ileg_mco$ | \sim MCO - Import des erreurs Leg |
| $imed_mco$ | \sim MCO - Import des Med |
| ipo | \sim MCO - Import des PO |
| $iano_mco$ | \sim MCO - Import des Anohosp |

Les données in / out sont prises en charge.

4.1.1 RSA

Selon la nature des analyses à produire, plusieurs types d'imports sont possibles :

```
Type Import

1 Light: Partie fixe
2 Light+: Partie fixe + stream en ligne (+) actes et das
3 Light++: Partie fixe + stream en ligne (++) actes, das, typaut um et dpdr des um
4 Standard: Partie fixe + creation des tables actes, das et rsa_um
5 Standard+: Partie fixe + creation des tables actes, das et rsa_um + stream (+)
6 Standard++: Partie fixe + creation des tables actes, das et rsa_um + stream (++)
```

```
library(pmeasyr)
# Import des rsa 2015 type 6
irsa(finess = 750100042,
    annee = 2015,
    mois = 12,
    path = '~/Documents/data/mco',
```

```
typi = 6) -> rsa15
View(rsa15$rsa)
View(rsa15$rsa_um)
View(rsa15$actes)
View(rsa15$das)
```

Les tables sont par défaut avec des libellés :

| NOFINESS Finess de l'établissement | NOVRSA Ruméro de version du RSA | CLE_RSA Clé RSA | NOVRSS \$ Numéro de version du RSS groupé | NOSEQTA \$ Numéro séquentiel des tarifs |
|--------------------------------------|-----------------------------------|-------------------|---|---|
| 750100042 | 222 | 0000000001 | 116 | 002 |
| 750100042 | 222 | 0000000002 | 116 | 002 |
| 750100042 | 222 | 000000003 | 116 | 002 |
| 750100042 | 222 | 000000004 | 116 | 002 |
| 750100042 | 222 | 0000000005 | 116 | 002 |
| 750100042 | 222 | 000000006 | 116 | 002 |
| 750100042 | 222 | 000000007 | 116 | 002 |
| 750100042 | 222 | 0000000008 | 116 | 002 |
| 750100042 | 222 | 0000000009 | 116 | 002 |
| 750100042 | 222 | 0000000010 | 116 | 002 |
| 750100042 | 222 | 0000000011 | 116 | 002 |
| 750100042 | 222 | 0000000012 | 116 | 002 |
| 750100042 | 222 | 0000000013 | 116 | 002 |
| 750100042 | 222 | 000000014 | 116 | 002 |
| 750100042 | 222 | 0000000015 | 116 | 002 |
| 750100042 | 222 | 0000000016 | 116 | 002 |
| 750100042 | 222 | 0000000017 | 116 | 002 |
| | | | | |

Figure 4.1: Capture d'une portion de la table rsa15\$rsa

4.1.2 RUM

```
# Import des rsum 2015
irum(finess = 750100042,
    annee = 2015,
    mois = 12,
    path = '~/Documents/data/mco')
```

Selon la nature des analyses à produire, plusieurs types d'imports sont possibles :

| Type | Import |
|------|---|
| 1 | XLight: Partie fixe |
| 2 | Light : Partie fixe + stream en ligne des actes, das et dad |
| 3 | Standard : Partie fixe + table actes, das, dad |
| 4 | Standard+: Partie fixe + stream + table actes, das, dad |

4.2. HAD

4.1.3 Colonnes stream

Exemples sur quelques rsa:

• actes : Actes CCAM du Rsa

| Cle RSA | actes |
|------------|------------------------------------|
| 0000000001 | EDSF004, EDSF004, JQGA004, JQGA004 |
| 0000000002 | EPLF002, DEQP003, DEQP007, DZQM006 |
| 0000000003 | EBQH002, EEQH002, YYYY180 |

• dpdrum : zones diagnostics des passages UM du Rsa

| Cle RSA | dpdrum |
|-------------|------------------|
| 0000000004 | Z098 I671 |
| 00000000005 | Z380, P741, Z380 |

 $\bullet\,$ das : zones diagnostics associes du Rsa

| Cle RSA | das |
|------------|--|
| 0000000006 | Z9580, Z9588 |
| 0000000007 | P011, P032, P036, P011, P032, P700, P011, P032, P036 |

• um : types autorisations T2A des um de passage par ordre chronologique

| Cle RSA | um |
|------------|------------------|
| 0000000009 | 01AC, 53 C |
| 0000000010 | 51 C |
| 0000000011 | 71 C, 04 C, 71 C |

Pour les quatre autres champs PMSI, seules les données du out sont prises en charge par le package pour le moment.

Les fonctions d'imports pour ces trois champs reposent sur le même principe qu'en MCO.

4.2 HAD

| Nom | Fonction |
|----------|---------------------------------|
| iano_had | \sim HAD - Import des Anohosp |
| imed_had | \sim HAD - Import des Med |
| irapss | \sim HAD - Import des RAPSS |

| actes Stream Actes | um \$\phi\$ Parcours Typaut UM | dpdrum \$\\phi\$ Stream DP/DR des UM | das \$ Stream Das |
|--|--------------------------------|--------------------------------------|--|
| JDLD001, DEQP003 | 07AC | N179 | |
| DEQP003, DEQP003 | 07AC | 1480 | |
| | 07AC | F100 | |
| | 07AC | T406 | |
| YYYY600, ACQJ002 | 07AC | R410 | B230, B582 |
| DEQP003 | 07AC | T509 | F603 |
| YYYY009, DEQP007, ZZEP004 | 04 C | P599 | |
| LFQK002, NEQK010, NAQK023 | 07AC | M796 | |
| EAQH002, DEQP003, ZBQK001, YYYY600 | 07AC | J449 | Z030, I618 |
| BGQP003, BLQP010, DEQP003, BJQP005, EQQP008, | 18 C | G459 | |
| | 07AC | F119 | F209 |
| DEQP003, JAQM003 | 07AC | N179 | |
| DEQP003 | 07AC | 1509 | |
| DEQP003, NAQK023 | 07AC | R53+0 | F023, G20, I480 |
| DEQP003, LFQK002, LEQK001 | 07AC | 1501 | |
| | 07AC | J189 | J458 |
| DEQP003, AFHB002, YYYY600, EBQH004 | 07AC | A879 | |
| DEQP003, DEQP003 | 07AC | J209 | |
| QAGA003, ZZLP054, ZZLP054, ZZQX180 | 53 P | M7958 | |
| | 29 P | Z502 | |
| EEAF003, EEAF003, EEAF003, YYYY200, N | 29 C | 17021 | E1140, E1150, Z713, Z718, L039, L030, Z740, E440 |
| FCFA008, FCFA008, GDFA011, GDFA011, ZZQX175 | 53 C | C328 | I10, Z921, J384, T814, B956 |
| ZCQM001, JAQM003 | 29 C | E1120 | Z713, N083, E559 |
| NDQK002, DEQP003 | 29 C | R02 | R2630, E1170, Z713 |

Figure 4.2: Capture des zones stream de la table <code>rsa15\$rsa</code>

4.5. RSF

```
path = '~/Documents/data/had') -> data_had
```

4.3 SSR

| Nom | Fonction | | |
|----------|---------------------------------|--|--|
| iano_ssr | \sim SSR - Import des Anohosp | | |
| irha | \sim SSR - Import des RHA | | |
| issrha | \sim SSR - Import des SSRHA | | |

```
irha(finess = 750041543,
    annee = 2015,
    mois = 12,
    path = '~/Documents/data/ssr') -> data_ssr
```

4.4 PSY

| Nom | Fonction |
|----------|--|
| iano_psy | $\sim \mathrm{PSY}$ - Import des Anohosp |
| ir3a | $\sim PSY$ - Import des R3A |
| irpsa | $\sim \mathrm{PSY}$ - Import des RPSA |

4.5 RSF

| Nom | Fonction |
|----------------|---------------------------------------|
| irafael | \sim RSF - Import des RSFA / Rafael |
| $iano_rafael$ | \sim RSF - Import des RSFA / ANO |

```
irafael(finess = 750712184,
    annee = 2015,
    mois = 12,
    path = '~/Documents/data/rsf') -> rsfa
```

4.6 Dictionnaire de variables

```
# Obtenir les noms, labels et types de variables (character, numeric, integer, date, ...)
dico(rsa15$rsa)
# Charger les formats de toutes les tables prises en charge par le package
pmeasyr::formats
```

Requêtes sur des pathologies / actes

5.1 Transposition des codes diagnostics

Les analyses sur les diagnostics CIM-10 sont parfois fastidieuses du fait des multiples positions de diagnostics : DP principal du séjour, DR principal du séjour, DPUM, DRUM, DAS. La fonction *tdiag* permet de rassembler tous les diagnostics dans une seule table.

```
# Pour les objets rsa et rum du MCO
# Transbahuter tous les diagnostics dans une seule table
tdiag(rsa15) -> rsa15 # "Tidy diagnostics"
View(rsa15$diags)
# Tous les diagnostics sont dans une table, avec un numero selon leur position
# 1:DP, 2:DR, 3:DPUM, 4:DRUM, 5:DAS
```

Exemple de résultat :

| CLE_RSA | NSEQRUM | position | diag |
|------------|---------|----------|------|
| 0000000001 | 01 | 1 | Z511 |
| 0000000001 | 01 | 2 | C18 |
| 0000000002 | 01 | 1 | C501 |
| 0000000002 | 01 | 3 | C501 |
| 0000000002 | 02 | 1 | D051 |
| 0000000002 | 02 | 5 | E109 |

5.2 Exemple 1 : recherche de codes diagnostics d'épilepsie

L'objectif est de récupérer les séjours présentant un code diagnostic de la liste

```
# quelle que soit la position du diagnostic
rsa15$diags %>% filter(diag %in% liste_diag)
# position en das
rsa15$diags %>% filter(diag %in% liste_diag, position == 5)
# position en dp dr
rsa15$diags %>% filter(diag %in% liste_diag, position < 5)

## En passant par les zones stream
string_diags =
    'F803|G400|G401|G402|G403|G404|G405|G406|G407|G408|G409|G410|G411|G412|418|G419|R568'

# quelle que soit la position du diagnostic
rsa15$rsa %>% fiter(grepl(string_diags, dpdrum)|grepl(string_diags, das))
# position en das
rsa15$rsa %>% fiter(grepl(string_diags, das))
# position en dpdr
rsa15$rsa %>% fiter(grepl(string_diags, dpdrum))
```

5.3 Exemple 2 : recherche de codes actes

```
# Code EBLA003

library(dplyr)
# En passant par la table actes
rsa15$actes %>% filter(CDCCAM == 'EBLA003')
# En passant par la zone stream
rsa15$rsa %>% filter(grepl('EBLA003', actes))
```

Étude des files actives

6.1 Import des données Anohosp

6.2 File active d'une pathologie

```
# Codes diagnostics obésité
string_diags = 'E66'

# position en dpdr
rsa15$rsa %>% filter(grepl(string_diags, dpdrum)) -> ob

# File active obésité globale établissement
inner_join(ano, ob, by = c('CLE_RSA')) -> patients_ob
distinct(patients_ob, NOANON) %>% nrow()
```

6.3 File active d'une chirurgie

Fichier TRA

Le fichier TRA est un fichier du out qui permet de relier les données anonymes du out aux données du in, il comprend un lien entre :

- MCO : clé rsa, numéro de rss, numéro de sejour (nas), date d'entrée et date de sortie du séjour
- SSR : numéro séquentiel du séjour + nosegrhs et numéro de séjour + numéro de semaine
- PSY RPSA : ipp, date d'entrée et de fin du sejour, numéro séquentiel du séjour, numéro de séquence et numéro de séjour, dates de début et fin de sequence
- PSY R3A: ipp, date de l'acte, numéro d'ordre, forme activité, um, nature et lieu de l'acte
- HAD : numéro séquentiel de séjour, numéro de séquence, sous-sequence et numéro de séjour, dates de début et fin des séquences et sous-séquences, dates d'entrée et de sortie du séjour, modes d'entrée sortie provenance destination

| Type | Import |
|--------------|---|
| itra | ~ TRA - Import du TRA |
| $inner_tra$ | $\sim {\rm TRA}$ - Ajout du TRA aux données Out |

7.1 Ajout du TRA en MCO

```
# lecture du fichier tra et jointure aux rsa
itra(750100042, 2015, 12, '~/Documents/data/mco') -> tra
# Ajout du tra aux rsa :
inner_tra(rsa15$rsa, tra) -> rsa15$rsa
```

7.2 Ajout du TRA en HAD

```
# Import du TRA HAD
itra(finess = 750712184,
    annee = 2015,
    mois = 12,
    path = '~/Documents/data/had',
    champ = "had") -> tra
# Ajout du tra
```

```
inner_tra(data_had$rapss, tra, champ = "had") -> data_had$rapss
inner_tra(data_had$acdi, tra, champ = "had") -> data_had$acdi
inner_tra(data_had$ght, tra, champ = "had") -> data_had$ght
```

7.3 Ajout du TRA en SSR

7.4 Ajout du TRA en PSY

```
# Import du TRA PSY : fichiers RPSA
itra(finess = 750803454,
    annee = 2015,
    mois = 12,
    path = '~/Documents/data/psy',
    champ = "tra_psy_rpsa") -> tra
# Ajout du tra
inner_tra(rpsa_psy$rpsa, tra, champ = "psyrpsa") -> rpsa_psy$rpsa
inner_tra(rpsa_psy$das, tra, champ = "psyrpsa") -> rpsa_psy$das
# Import du TRA PSY : fichiers R3A
itra(finess = 750803454,
    annee = 2015,
    mois = 12,
    path = '~/Documents/data/psy',
     champ = "tra_psy_r3a") -> tra
# Ajout du tra
inner_tra(r3a_psy$r3a, tra, champ = "psyr3a") -> r3a_psy$r3a
inner_tra(r3a_psy$das, tra, champ = "psyr3a") -> r3a_psy$das
```

Statistiques du PMSI

- âge moyen des patients
- Durée de séjour
- Nombre de séjours par catégorie majeure de diagnostics
- Case-mix MCO, DMS par GHM / GHS

```
# Age moyen et DMS sur les plus de 0 jour
rsa15$rsa %>% summarise(age_moyen = mean(AGEAN),
                        dms = mean(if_else(DUREE>0, DUREE, NA), na.rm = T))
# Nombre de séjours par catégorie majeure de diagnostics
rsa15$rsa %>% count(RSACMD)
# Construire la variable GHM
rsa15$rsa %>% tidyr::unite(GHM,
                           RSACMD, RSATYPE, RSANUM, RSACOMPX,
                           sep = "") -> rsa15$rsa
\# Case-mix par GHM
rsa15$rsa %>% count(GHM)
# Case-mix par GHM / GHS
rsa15$rsa %>% count(GHM, NOGHS)
# DMS par GHM / GHS
rsa15$rsa %>% group_by(GHM, NOGHS) %>%
  summarise(dms = mean(if_else(DUREE>0, DUREE, NA), na.rm = T))
```

Help

Toutes les fonctions du package ont une page d'aide :

?irsa

?irum

?irapss